

성민규

AI Research Engineer — 효율적 생성모델 추론 (양자화 · 캐싱 · 가속)

Nota AI, Platform팀 (Quantizer) · 대한민국

Nota AI Platform팀 Quantizer 파트의 AI Research Engineer. 인공지능학 박사 (경북대, 2026). 효율적 생성모델 추론 연구: 모델 양자화, 디퓨전/LLM 캐시 가속, CUDA 커널 최적화, split computing, training-free KV-cache 압축. Nunchaku CUDA 가속 엔진 (ICLR 2025 Spotlight) 핵심 기여자; Nunchaku, ComfyUI-nunchaku, ByteDance DreamO, Hugging Face Transformers에 총 15개 PR 머지.

경력

AI Research Engineer — Platform팀 Quantizer 파트

2026.02 – 현재

Nota AI

- LLM/VLM 양자화 플랫폼: GPTQ, AWQ, SmoothQuant, QuaRot/SpinQuant 파이프라인; NVFP4-GGUF export 경로; MoE all-expert calibration; KV-cache 양자화 (머지된 사내 PR 기록으로 검증 가능).
- 모델 지원 및 평가: EXAONE 4.0 / MoE, Qwen3 / 3.5(-VL), Phi-3 (LongRoPE), gpt-oss, embedding/reranker 및 비디오 디퓨전 (Wan, Cosmos) 평가 하네스.
- LG AI Research 협업, FuriosaAI 데이터센터 NPU용 K-EXAONE 236B (MoE) 최적화 — 모델 크기 약 71% 감축, 정확도 약 99.2% 유지 (GPQA 79.80, IFBench 68.98, AIME25 88.57); 2026-06-30 공개.

학력

박사 (Ph.D.), 인공지능학과

2021.08 – 2026.02

경북대학교 (KNU) · 학위논문: Fast and Trustworthy Super-Resolution with VLM-Guided Diffusion Model

석사 (M.S.), 컴퓨터학부

2019.09 – 2021.08

경북대학교 (KNU) · 학위논문: Probabilistic Classification Method of Spiking Neural Network Based on Multi-Labeling of Neurons

학사 (B.S.), 컴퓨터학부

2013.03 – 2019.08

경북대학교 (KNU)

연구

StreamPRS

2026

KVzip의 재구성 기반 KV-cache 추출을 단일-context-prefill로 근사; 기여는 Factorization / Method / System으로 규정. (claims ledger 기준 범위-한정 — 과장 금지.)

오픈소스 기여

Nunchaku — Core Contributor

2025 – 2026-02

nunchux-ai/nunchaku · 9 머지된 PR · 4-bit 신경망용 CUDA 가속 엔진 (ICLR 2025 Spotlight, 3.9k+ stars)

- 캐시 최적화 설계-구현 — V2 FBCaching (#621), double FB cache, TeaCache 배치 처리 (#601) — 추가 2-5배 가속
- IP-Adapter (XLabs flux-ip-adapter-v2) 지원 (#418)
- 수정: LoRA 키 불일치 (#557), ControlNet (#360, #452), Sana (#380), offload segfault (#440)
- forward-pass 텐서 연산 정리 (#491)

ComfyUI-nunchaku — Contributor

2025

nunchux-ai/ComfyUI-nunchaku · 2 머지된 PR · Nunchaku 엔진의 ComfyUI 연동

- ComfyUI용 IP-Adapter 지원 (#305)
- 캐시 메커니즘 파일 분리 (#474)

DreamO — Contributor

2025

bytedance/DreamO · 1 머지된 PR · ByteDance의 통합 이미지 커스터마이제이션 프레임워크

- Nunchaku 엔진 연동을 위한 동적 FBCache / DoubleFBCache 지원 (#104)

Transformers — Contributor

2026

huggingface/transformers · 3 머지된 PR · Hugging Face Transformers 라이브러리

- Gemma4 vision pooler의 float16 오버플로 수정 (#46277)
- config 저장/로드마다 Gemma sliding_window가 반감되던 결함 수정 — EmbeddingGemma의 무증상 정확도 회귀 (#47940)
- 양자화된 자식 모듈의 weight를 읽던 _init_weights 수정 — CLIP 계열 양자화 체크포인트 로드 실패 (#47921)

논문

[J1] H2-Cache: A Novel Hierarchical Dual-Stage Cache for High-Performance Acceleration of Generative Diffusion Models

M. Sung, I.-M. Kim, S. Yun, J.-M. Kang · IEEE Open Journal of the Computer Society · 2025

[J2] A Novel VLM-Guided Diffusion Model for Remote Sensing Image Super-Resolution

M. Sung, M.-G. Gong, S.-J. Ham, I.-M. Kim, S. Yun, J.-M. Kang · IEEE Geoscience and Remote Sensing Letters · 2025

[J3] DeCo-MeSC: Deep Compression-Based Memory-Constrained Split Computing Framework for Cooperative Inference of Neural Network

M. Sung, V. Palakonda, I.-M. Kim, S. Yun, J.-M. Kang · IEEE Transactions on Vehicular Technology · 2025

[J4] Generative Diffusion Model-Based Deep Learning Framework for Remaining Useful Life Prediction
S. Ha, **M. Sung**, F. Saeed, S. Yun, I.-M. Kim, J.-M. Kang · IEEE Internet of Things Journal · 2025

[J5] Entropy-based sampling for efficient training of deep learning on CNC machining dataset
M. Sung, C. Park, S. Ha, M. Ha, H. Lee, J. Kim, J.-M. Kang · Electronics Letters · 2024

[J6] Probabilistic Classification Method of Spiking Neural Network Based on Multi-Labeling of Neurons
M. Sung, J. Kim, J.-M. Kang · Mathematics · 2023

[J7] Training and Inference using Approximate Floating-Point Arithmetic for Energy Efficient Spiking Neural Network Processors
M. Kwak, J. Lee, H. Seo, **M. Sung**, Y. Kim · ICEIC · 2021

[J8] Training spiking neural networks with an adaptive leaky integrate-and-fire neuron
M. Sung, Y. Kim · IEEE ICCE-Asia · 2020

PREPRINT

[P1] GLYPH-SR: Can We Achieve Both High-Quality Image Super-Resolution and High-Fidelity Text Recovery via VLM-guided Latent Diffusion Model?
arXiv:2510.26339 · 2025

[P2] Memory- and Latency-Constrained Inference of Large Language Models via Adaptive Split Computing
arXiv:2511.04002 · 2025

[P3] No Pose Estimation? No Problem: Pose-Agnostic and Instance-Aware Test-Time Adaptation for Monocular Depth Estimation
arXiv:2511.05055 · 2025

[P4] Why Should the Server Do It All?: A Scalable, Versatile, and Model-Agnostic Framework for Server-Light DNN Inference over Massively Distributed Clients via Training-Free Intermediate Feature Compression
arXiv:2511.11608 · 2025

[P5] Range Asymmetric Numeral Systems-Based Lightweight Intermediate Feature Compression for Split Computing of Deep Neural Networks
arXiv:2511.11664 · 2025

주요 프로젝트

K-EXAONE 236B MoE 최적화 (Nota AI × LG AI Research × FuriosaAI) 

성능 저하 구간 정밀 분석 기반 타킷 최적화로 236B MoE 모델을 FuriosaAI 데이터센터 NPU용으로 최적화 — 모델 크기 약 71% 감축, 정확도 약 99.2% 유지 (GPQA 79.80 / IFBench 68.98 / AIME25 88.57).

LLM 추론 최적화 (Samsung Challenge)

Torch-TensorRT 변환과 메모리 인지 동적 배칭으로 Phi-3 추론 가속 파이프라인 설계.

첨단 CNC 공작기계 진단·예지 (한국전기연구원 KERI)

공구 마모 분류, 이상 감지, RUL 예지용 딥러닝 모델 개발 주도.

AI 기반 지능형 CCTV (ABB 과제)

LSTR 행동 감지 모델을 엣지 디바이스용으로 최적화 — Knowledge Distillation (TransKD)과 Deep Compression으로 25배 모델 압축.

글로벌 기초연구실 (NRF 과제)

IRS 기반 통신 시스템을 위한 딥러닝 채널 추정 (CNN 디노이징, 자기지도학습) 개발.

ML 기반 센서 데이터 분석 (JS System 과제)

ML 기반 센서 feature-importance 추출 및 모델 성능 최적화 주도.

수상

Best Paper Award · KNU-EE Research Congress

A Novel VLM-Guided Diffusion Model for Remote Sensing Image Super-Resolution

2025

기술

연구	모델 양자화, KV-cache 압축, 디퓨전/LLM 추론 가속, split computing, 초해상도, 롱컨텍스트 평가
프로그래밍	Python, C++, CUDA C, MATLAB
프레임워크·도구	PyTorch, HuggingFace Transformers, TensorRT, Triton, flash-attn, Docker, Git, LaTeX
방법론	사전등록, claims ledger, freeze 규율
언어	한국어 (native) · 영어 (비즈니스 회화 가능)