mingyu.sung@nota.ai
bluear7878.github.io
github.com/Bluear7878
Google Scholar
LinkedIn
51 인용 · h-index 4

성민규

AI Research Engineer — 효율적 생성모델 추론 (양자화 · 캐싱 · 가속)

Nota AI, Platform팀 (Quantizer) · 대한민국

관심 분야 LLM·VLM·VLA·디퓨전 등 모델 종류에 관계없이 효율적 추론 — 양자화, KV-cache 압축, 캐시 가속, speculative decoding, 커널 최적화

학력 경북대학교 인공지능학 박사 (2026)

오픈소스 Nunchaku CUDA 가속 엔진 (ICLR 2025 Spotlight) 핵심 기여자; Nunchaku, Hugging Face Transformers, ByteDance DreamO 등에 총 16개 PR 머지

경력

AI Research Engineer — Platform팀 Quantizer 파트
2026.02 – 현재

Nota AI

- Nota LLM/VLM 양자화 플랫폼 개발: PTQ 알고리즘(GPTQ, AWQ, SmoothQuant, 회전 기반), KV-cache 양자화, 저비트 export(NVFP4, GGUF).
- LLM·VLM·MoE·임베딩·비디오 디퓨전 모델의 지원 및 평가 범위 확장.
- LG AI Research 협업, FuriosaAI 데이터센터 NPU용 K-EXAONE 236B (MoE) 최적화 — 모델 크기 약 71% 감축, 정확도 약 99.2% 유지.

학력

박사 (Ph.D.), 인공지능학과
2021.08 – 2026.02

경북대학교 (KNU) · 학위논문: Fast and Trustworthy Super-Resolution with VLM-Guided Diffusion Model

석사 (M.S.), 컴퓨터학부
2019.09 – 2021.08

경북대학교 (KNU) · 학위논문: Probabilistic Classification Method of Spiking Neural Network Based on Multi-Labeling of Neurons

학사 (B.S.), 컴퓨터학부
2013.03 – 2019.08

경북대학교 (KNU)

오픈소스 기여

Nunchaku — Core Contributor
2025 – 2026-02

nunchux-ai/nunchaku · 9 머지된 PR · 4-bit 신경망용 CUDA 가속 엔진 (ICLR 2025 Spotlight, 3.9k+ stars)

- 캐시 최적화 설계·구현 — V2 FBCaching (#621), double FB cache, TeaCache 배치 처리 (#601) — 추가 2–5배 가속
- IP-Adapter (XLabs flux-ip-adapter-v2) 지원 (#418)
- 수정: LoRA 키 불일치 (#557), ControlNet (#360, #452), Sana (#380), offload segfault (#440)
- forward-pass 텐서 연산 정리 (#491)

ComfyUI-nunchaku — Contributor
2025

nunchux-ai/ComfyUI-nunchaku · 2 머지된 PR · Nunchaku 엔진의 ComfyUI 연동

- ComfyUI용 IP-Adapter 지원 (#305)
- 캐시 메커니즘 파일 분리 (#474)

DreamO — Contributor
2025

bytedance/DreamO · 1 머지된 PR · ByteDance의 통합 이미지 커스터마이제이션 프레임워크

- Nunchaku 엔진 연동을 위한 동적 FBCache / DoubleFBCache 지원 (#104)

Transformers — Contributor
2026

huggingface/transformers · 3 머지된 PR · Hugging Face Transformers 라이브러리

- Gemma4 vision pooler의 float16 오버플로 수정 (#46277)
- config 저장/로드마다 Gemma `sliding_window`가 반감되던 결함 수정 — EmbeddingGemma의 무증상 정확도 회귀 (#47940)
- 양자화된 자식 모듈의 `weight`를 읽던 `_init_weights` 수정 — CLIP 계열 양자화 체크포인트 로드 실패 (#47921)

LoopQuant — Contributor
2026

Kishon-zzx/LoopQuant · 1 머지된 PR · 반복 블록 언어모델(looped LM, Ouro)용 사후 양자화 (PTQ)

- LCTC teacher 로드가 ILPA의 loop별 activation 비트 배정을 재설정해 W4A6 설정이 모든 loop를 A4로 실행하던 결함 수정 — 수정 후 Ouro-2.6B W4A6 WikiText-2 perplexity 8.10 → 7.85 (#1)

논문

[J1] **A Bi-Objective Framework for Scene Text Super-Resolution: Balancing Legibility and Fidelity**
M. Sung, S. Ham, K. Kim, I.-M. Kim, S. Yun, J.-M. Kang · Transactions on Machine Learning Research (TMLR) · 2026

[J2] **H2-Cache: A Novel Hierarchical Dual-Stage Cache for High-Performance Acceleration of Generative Diffusion Models**
M. Sung, I.-M. Kim, S. Yun, J.-M. Kang · IEEE Open Journal of the Computer Society · 2025

[J3] **A Novel VLM-Guided Diffusion Model for Remote Sensing Image Super-Resolution**
M. Sung, M.-G. Gong, S.-J. Ham, I.-M. Kim, S. Yun, J.-M. Kang · IEEE Geoscience and Remote Sensing Letters · 2025

[J4] **DeCo-MeSC: Deep Compression-Based Memory-Constrained Split Computing Framework for Cooperative Inference of Neural Network**
M. Sung, V. Palakonda, I.-M. Kim, S. Yun, J.-M. Kang · IEEE Transactions on Vehicular Technology · 2025

[J5] Generative Diffusion Model-Based Deep Learning Framework for Remaining Useful Life Prediction
S. Ha*, **M. Sung***, F. Saeed, S. Yun, I.-M. Kim, J.-M. Kang · IEEE Internet of Things Journal · 2025

[J6] Entropy-based sampling for efficient training of deep learning on CNC machining dataset
M. Sung, C. Park, S. Ha, M. Ha, H. Lee, J. Kim, J.-M. Kang · Electronics Letters · 2024

[J7] Probabilistic Classification Method of Spiking Neural Network Based on Multi-Labeling of Neurons
M. Sung, J. Kim, J.-M. Kang · Mathematics · 2023

[J8] Training and Inference using Approximate Floating-Point Arithmetic for Energy Efficient Spiking Neural Network Processors
M. Kwak, J. Lee, H. Seo, **M. Sung**, Y. Kim · ICEIC · 2021

[J9] Training spiking neural networks with an adaptive leaky integrate-and-fire neuron
M. Sung, Y. Kim · IEEE ICCE-Asia · 2020

* 공동 1저자

PREPRINT

[P1] RECAP-KV: Single-Prefill Approximation of Reconstruction Importance for Reusable KV Cache Eviction
OpenReview · 2026

[P2] Memory- and Latency-Constrained Inference of Large Language Models via Adaptive Split Computing
M. Sung, V. Palakonda, S. Im, S. Moon, I.-M. Kim, S. Yun, J.-M. Kang · arXiv:2511.04002 · 2025

[P3] No Pose Estimation? No Problem: Pose-Agnostic and Instance-Aware Test-Time Adaptation for Monocular Depth Estimation
M. Sung, H. Choe, I.-M. Kim, S. Yun, J.-M. Kang · arXiv:2511.05055 · 2025

[P4] Why Should the Server Do It All?: A Scalable, Versatile, and Model-Agnostic Framework for Server-Light DNN Inference over Massively Distributed Clients via Training-Free Intermediate Feature Compression
M. Sung, S. Im, D. Bang, I.-M. Kim, S. Yun, J.-M. Kang · arXiv:2511.11608 · 2025

[P5] Range Asymmetric Numeral Systems-Based Lightweight Intermediate Feature Compression for Split Computing of Deep Neural Networks
M. Sung, S. Im, V. Palakonda, J.-M. Kang · arXiv:2511.11664 · 2025

주요 프로젝트

K-EXAONE 236B MoE 최적화 (Nota AI × LG AI Research × FuriosaAI) ↗ — Quantization Engineer · 2026
성능 저하 구간 정밀 분석 기반 타깃 최적화로 236B MoE 모델을 FuriosaAI 데이터센터 NPU용으로 최적화 — 모델 크기 약 71% 감축, 정확도 약 99.2% 유지 (GPQA 79.80 / IFBench 68.98 / AIME25 88.57).

LLM 추론 최적화 (Samsung Challenge) — Lead Developer · 2024
Torch-TensorRT 변환과 메모리 인지 동적 배칭으로 Phi-3 추론 가속 파이프라인 설계.

첨단 CNC 공작기계 진단·예지 (한국전기연구원 KERI) — Lead Developer · 2023
공구 마모 분류, 이상 감지, RUL 예지용 딥러닝 모델 개발 주도.

AI 기반 지능형 CCTV (ABB 과제) — AI Optimization Engineer · 2023
LSTR 행동 감지 모델을 엣지 디바이스용으로 최적화 — Knowledge Distillation (TransKD)과 Deep Compression으로 25배 모델 압축.

글로벌 기초연구실 (NRF 과제) — Participating Researcher · 2022
IRS 기반 통신 시스템을 위한 딥러닝 채널 추정 (CNN 디노이징, 자기지도학습) 개발.

ML 기반 센서 데이터 분석 (JS System 과제) — Lead Developer · 2022
ML 기반 센서 feature-importance 추출 및 모델 성능 최적화 주도.

수상

Best Paper Award · KNU-EE Research Congress — 2025
A Novel VLM-Guided Diffusion Model for Remote Sensing Image Super-Resolution

기술

연구	모델 양자화, KV-cache 압축, 디퓨전/LLM 추론 가속, split computing, 초해상도, 롱컨텍스트 평가
프로그래밍	Python, C++, CUDA C, MATLAB
프레임워크·도구	PyTorch, HuggingFace Transformers, TensorRT, Triton, flash-attn, Docker, Git, LaTeX
방법론	사전등록, claims ledger, freeze 규율
언어	한국어 (native) · 영어 (비즈니스 회화 가능)